

本編 (6 枚 / 発表 ~6 分)

各スライドは --- で区切り。囲み数式は LaTeX ($\dots$, $\dots$) で書く。
発表者は **手法パート**を担当する想定。結果・考察は他メンバーが補足する前提でサマリのみ載せる。
スライド外の詳細 (Polarity の循環論法回避、Quality スコア、頑健性、想定質問) は本ファイル後半の **Appendix** に温存。

スライド 1 – 問いと仮説

問い: Community Notes は「陣営反応」で潰されているのか？
— 政治的に不都合な note に対し、反対陣営が短時間で集中的に Not Helpful を押し、合意形成を妨げているのではないか。

仮説の切り分け: バーストを 2 種類に分けて比較する。

種別	定義（直感）	役割
TypeA	「同じ陣営」が集中評価したバースト	陣営反応の指標
TypeB	「いろんな陣営」が集中評価したバースト	自然拡散の指標（対照）

判定: TypeA のみ有意 ($p < 0.05$, $\beta_{\text{typeA}} > 0$) なら **仮説支持**。両方有意なら $|\beta|$ の大小で主因を議論。

スライド 2 – データとパイプライン全体像

データ: X が公開する Community Notes の 3 種 TSV（日次更新）

- notes-*.tsv (本文・分類) / ratings-*.tsv (評価ログ) / noteStatusHistory-*.tsv (最終ステータス)
- 本番 SAMPLE_FRAC = 0.30 で noteld 単位サンプリング

パイプライン (scripts/run_simple.py の 6 ステップ)

1. notes 読込 → 政治トピックで絞り込み → noteld を frac サンプリング
2. 該当 ratings / history のみチャンク読み
3. **Polarity 計算** (TruncatedSVD, 次元 2) — 各 rater を 2D ベクトルに
4. **バースト検出 + TypeA / TypeB 分類**
5. **Quality スコア** (LLM ラベル学習済の固定重み)
6. **ロジスティック回帰** (相関行列 / VIF 診断つき)

本編では 3-4 と 6 を中心に説明。1, 2, 5 は appendix 参照。

スライド 3 — 手法 ① Polarity (評価者の立場ベクトル)

目的: 各 rater を 2D ベクトル (x, y) で表し「似た note を同じように評価する人」を近づける。

手順

1. 評価を数値化:

$$s = \begin{cases} +1 & \text{HELPFUL} \\ 0 & \text{SOMEWHAT_HELPFUL} \\ -1 & \text{NOT_HELPFUL} \end{cases}$$

2. 各 rater の最初の $N = 50$ 件だけ採用（後述の循環論法回避のため）。
3. 疎行列 $M \in \mathbb{R}^{R \times N_{\text{note}}}$ に対し **Truncated SVD** で rank-2 近似:

$$M \approx U_2 \Sigma_2 V_2^\top, \quad \text{polarity}_i = U_2[i, :] \cdot \Sigma_2$$

「最初の 50 件」の理由 (循環論法回避): 全期間の評価を使うと「note が削除された後」の評価も polarity に混ざり、polarity が目的変数 deleted の情報を含んでしまう (target leakage)。先頭 50 件で固定すれば polarity は **時間的に先行する** 量になる。

スライド 4 — 手法 ② バースト検出と TypeA/B 分類

バースト条件 (1 ノート内・連続 $k = 5$ 件のウィンドウ):

$$v_{\text{local}}(i) = \frac{k}{\max(t_{i+k-1} - t_i, 1\text{ms})} \geq 3.0 \cdot v_{\text{avg}}$$

直感: 「**その note の普段ペースの 3 倍以上速く、5 件連続で評価が来た区間**」。1 note につき先頭 1 バーストのみ採用。

TypeA / TypeB 分類 — バースト中 k 人の polarity 分散の和を計算:

$$V = \text{Var}(x_1, \dots, x_k) + \text{Var}(y_1, \dots, y_k)$$

$$\text{burst_type} = \begin{cases} A & V \leq \tilde{V} \quad (\text{同じ陣営} = \text{陣営反応}) \\ B & V > \tilde{V} \quad (\text{バラバラ} = \text{自然拡散}) \end{cases}$$

$\tilde{V}$ は全バーストの V の **中央値**。相対基準にすることでサンプル依存を避ける。

スライド 5 — 手法 ③ ロジスティック回帰

目的変数: $\text{deleted} = 1[\text{status} = \text{CURRENTLY_RATED_NOT_HELPFUL}]$

回帰式 (log-odds):

$$\log \frac{\Pr(\text{deleted}=1)}{\Pr(\text{deleted}=0)} = \beta_0$$

- β_1, type_a
- β_2, type_b
- $\beta_3, \text{quality}$
- $\beta_4, \log(1 + \text{ratings_count})$

設計上のポイント

- $\text{type}_a, \text{type}_b \in \{0, 1\}$ (1 note 1 バーストなので両方 1 にはならない)
- $\log(1 + \text{ratings_count})$ で**人気度を control** — バーストは構造的に評価数と正相関するため必須
- ナイーブな trend (前半-後半スコア) は目的変数と同じ生データ由来の **bad control** なので除外
- 相関行列と VIF を自動 print し多重共線性を確認

スライド 6 — 結果と判定

実行条件: SAMPLE_FRAC = 0.30 , SEED = 42 / N = 14,253 (政治 notes), deleted 28.4%

ロジスティック回帰 (deleted ~ type_a + type_b + quality + log_ratings_count)

変数	β	p
type_a	−1.129	< 0.001
type_b	−0.404	< 0.001
quality	−1.865	< 0.001
log_ratings_count	−0.603	< 0.001
(const)	+3.727	< 0.001

判定: 仮説は棄却 — それも 逆方向に有意

- $\beta_{\text{typeA}} = -1.13$ と強く負 → バーストを持つ note はむしろ 削除されにくい
- $|\beta_{\text{typeA}}| > |\beta_{\text{typeB}}|$ で TypeA の "保護効果" のほうが強い

解釈: TypeA は polarity 分散のみを見ており、投票方向 (Helpful / Not Helpful) を区別していない。同陣営の集中投票には「攻撃」と「防衛」の両方が混ざる。実データでは 支持陣営による防衛 rally が多数派だった可能性が高い。

→ 設計拡張 (pro-rally / con-rally 分割) が今後の課題。頑健性は SEED=1 でも同符号・同桁・ $p < 0.001$ で再現済 (appendix)。

Appendix (補助スライド・必要に応じて表示)

以下は本編から外した詳細・補助資料。手法の細部、Quality スコア設計、頑健性チェック、想定質問など。

A1 — 政治トピック抽出 / サンプルリング

- ノート本文 `summary` を **単語境界** `\b` 付き正規表現でフィルタ（政治キーワード辞書、約 40 語: `trump, election, abortion, immigration, supreme court, ...`）。
 - 旧実装の単純な部分一致では `vote` → `devote` / `voter` 等が誤マッチしていたため `\b...\b` で囲った。
- サンプルリング (`noteId` 単位、`rater` 単位ではない) :

```
sample_ids = RandomSample({noteId}_political, frac, seed)
```

- デフォルト `frac = 0.30` , `seed = 42` （再現性のため固定）
- サンプルリング済 `noteId` に紐づく `ratings` のみチャンク読み → メモリ節約
- 頑健性チェック: `seed` を 1, 2, 3 と変え β_{typeA} がブレないか確認。

A2 — Polarity 詳細 (SVD と < 5 件除外)

- 評価を数値化 (+1/0/ - 1)
- 各 `rater` の最初の $N = 50$ 件だけ採用
- 疎行列 $M \in \mathbb{R}^{R \times N_{\text{note}}}$ を作る:

$$M_{ij} = s_{ij} \quad (\text{rater } i \text{ が note } j \text{ に付けた score})$$

- Truncated SVD** で rank-2 近似:

$$M \approx U_2 \Sigma_2 V_2^\top, \quad U_2 \in \mathbb{R}^{R \times 2}$$

rater i の `polarity` = $U_2[i, :] \cdot \Sigma_2$ (sklearn の `fit_transform` の返り値)。

- < 5 件しか評価していない `rater` は除外（雑音防止）。

2次元のうち第1成分が「左右」、第2成分がそれと直交する変動を捉える。

A3 — なぜ「最初の 50 件だけ」なのか（循環論法回避）

もし全期間の評価を使うと:

- 「note が Not Helpful になった後」の評価も `polarity` に混ざる

- ⇒ polarity はすでに **目的変数 (deleted) の情報を含んだ量**になる
- ⇒ その polarity で TypeA/B を決めて回帰すると、**目的変数で説明変数を作っている** (target leakage)

対策: rater 単位で時系列ソート → 先頭 50 件だけで polarity を固定。

→ polarity は「その人が普段どっち陣営か」を表す **時間的に先行する量** になる。

A4 — バースト検出の詳細

全体の平均評価速度:

$$v_{\text{avg}} = \frac{n_{\text{total}}}{t_{\text{last}} - t_{\text{first}}} \quad (1 \text{ note 内})$$

局所速度 (連続する $k = \text{MIN_COUNT} = 5$ 件のウィンドウ):

$$v_{\text{local}}(i) = \frac{k}{\max(t_{i+k-1} - t_i, 1 \text{ ms})}$$

バースト条件:

$$v_{\text{local}}(i) \geq \alpha \cdot v_{\text{avg}}, \quad \alpha = \text{BURST_MULTIPLIER} = 3.0$$

条件を満たす i が見つかったら、その区間をバーストとする。簡略化のため **1 note につき最初の 1 バーストのみ**採用。

A5 — TypeA/B 分類の設計詳細

polarity が決まる rater が 2 人未満のバーストの扱い (= 分類不能):

- バースト行ごと除外 → そのノートは「バーストなし」として回帰に入る (type_a = type_b = 0)。
- 旧実装は強制 B にしていたがバイアスを生むため不採用。
- NaN を残して回帰側で dropna する案も試したが NA 比較で TypeError になるため不採用。

設計のポイント

- 閾値を中央値にすることで「この研究全体で相対的にどうか」を見る設計（絶対閾値はサンプル依存になる）。
- 1 ノート 1 バーストなので type_a と type_b が同時に 1 になることはない。

A6 — Quality スコア（LLM 学習済重み）

事前学習: Claude が 200 件の note に $\{0, 1\}$ ラベル付 → ロジスティック回帰で係数学習（CV AUC = 0.894）。

本パイプラインでは**固定重み**を使う：

特徴量 $f_k \in \{\text{url_count}, \text{char_count}, \text{domain_trust}\}$ を標準化してから線形和：

$$z = \beta_0 + \sum_k \beta_k \cdot \frac{f_k - \mu_k}{\sigma_k}$$
$$\text{quality} = \sigma(z) = \frac{1}{1 + e^{-z}} \in [0, 1]$$

変数	係数 β_k	寄与度 ($ \beta $ の比)
domain_trust	1.285	44%
char_count	0.962	33%
url_count	0.654	23%
(intercept)	0.519	—

「信頼できるドメインの URL があるか」が最重要、という LLM ラベルの事前知識と整合。

A7 — 実装と再現性

- リポジトリ: `hirototoda/toriumi_x3 / notebook` は `notebooks/colab_simple.ipynb`
- 設定セル 1 箇所編集するだけで実験可能:
 - SAMPLE_FRAC — サンプルリング率
 - SEED — 乱数シード（頑健性チェック用）
 - POLARITY_FIRST_N — polarity 固定に使う先頭件数

- BURST_MULTIPLIER , BURST_MIN_COUNT — バースト閾値
- 頑健性チェック: 本番 SAMPLE_FRAC = 0.30 で SEED = 42 を本実行とし、SEED = 1 を保険として 1 本追加実行済。
 - β_{typeA} : SEED=42 で -1.129 、SEED=1 で $-1.020 \rightarrow$ 同符号・同桁で再現。差 (0.11) は標準誤差 (≈ 0.10) と同程度。
 - 他の 3 係数 (type_b , quality , log_ratings_count) も全て同符号・同桁・ $p < 0.001$ で安定。
 - $p < 0.001$ が両 SEED で得られているため、SEED=2,3 は省略（時間制約と限界効用の観点）。
 - スモークテスト (frac=0.01) は検出力が低く SEED 振りで判定がパタつくため、頑健性チェックの対象外（パイプライン動作確認に専念）。

A8 — 結果フル表 + 頑健性

サンプル

- N = 14,253 (政治トピック notes, frac=0.30)
- deleted = 4,049 (28.4%) / helpful = 10,204 (71.6%)
- TypeA バースト持ち note = 7,990 / TypeB バースト持ち note = 5,705 / バーストなし = 558
- 検出バースト総数 = 106,673 (note 単位は最初の 1 バーストのみ採用)

ロジスティック回帰 (deleted ~ type_a + type_b + quality + log_ratings_count)

変数	β	p	95% CI
type_a	-1.129	< 0.001	$[-1.333, -0.926]$
type_b	-0.404	< 0.001	$[-0.610, -0.198]$
quality	-1.865	< 0.001	$[-2.005, -1.724]$
log_ratings_count	-0.603	< 0.001	$[-0.646, -0.559]$
(const)	$+3.727$	< 0.001	$[3.478, 3.975]$

- Pseudo R^2 (Cox–Snell) = 0.147, $\log L = -7376.4$, Deviance = 14,753

符号の妥当性チェック

- quality ↓ (-1.87): 質の高い note ほど消えにくい（事前予想と一致）

- `log_ratings_count` $\downarrow$ (-0.60): 評価数の多い note ほど消えにくい (人気度 control が効いている)
- バースト 2 変数も含めて 4 変数すべて負 $\rightarrow$ 「注目された / 質が高い note は消えにくい」という一貫した像。

頑健性 (SEED=1 を保険として追加実行済): 全 4 係数が同符号・同桁・ $p < 0.001$ で再現。

変数	SEED=42 β	SEED=1 β	p
<code>type_a</code>	-1.129	-1.020	< 0.001 (両 run)
<code>type_b</code>	-0.404	-0.384	< 0.001 (両 run)
<code>quality</code>	-1.865	-1.752	< 0.001 (両 run)
<code>log_ratings_count</code>	-0.603	-0.615	< 0.001 (両 run)

SEED=1 では $N=14,170$ / $deleted=3,904$ (27.6%) / $TypeA=7,795$ / $TypeB=5,833$ / バースト総数 106,836。サンプル構成も SEED=42 ($N=14,253$) と整合。

限界

- 政治トピック判定がキーワードベース / `polarity` 次元 2 / note 単位集計
- `TypeA` は投票方向を区別しないため、本設計では「陣営反応 = 攻撃」と「陣営防衛 = 防御」を分離できない ($\rightarrow$ 今後の課題)
- `frac=0.30` 単一規模での検証 (SEED=42 と SEED=1 の 2 本で頑健性は確認済)

A9 — 想定質問

結果の解釈について

- 「 β_{typeA} が負になった = 仮説とは逆だが、これは何を意味する?」
 $\rightarrow$ `TypeA` の定義はバースト参加者の `polarity` 分散のみを見ており、**投票の方向 (Helpful / Not Helpful)** を区別していない ([src/simple/burst.py:62-98](#))。同陣営の集中投票には「反対派が note を攻撃」と「支持派が note を防衛」の両方が混ざる。本番で $\beta_{typeA} = -1.13$ と強い負だったことは、実データでは**防衛 rally のほうが多数派**だった可能性が高いことを示唆する。"陣営反応" 仮説の正面検証には設計拡張が必要 (下記)。
- 「**TypeA を pro-rally / con-rally に分けたらどうなるの?**」
 $\rightarrow$ 本研究では未実装。バースト中の評価の `helpfulnessLevel` の平均符号で 2 分する拡張が考えら

れる。今後の課題。

- 「両方有意（負）の場合、コード側の判定文は何と出る？」

→ 現状 [src/simple/regression.py:127-130](#) の verdict 文字列は **符号を見ず p のみ** で判定するため、「TypeA/B 両方有意 → 自然拡散も寄与 (仮説部分支持)」と出る。発表ではスライド 6 で **符号を踏まえた判定** に上書きしている。

設計の妥当性

- 「TruncatedSVD で次元 2 にするのは根拠ある？」

→ [src/simple/polarity.py](#) で `explained_variance_ratio_` を出力。本番実測値 (frac=0.30, SEED=42, N_rater=401,045): **PC1=0.2%, PC2=0.1%**。比率が小さいのは rater×note 行列が極端に疎 (401k×N、ほぼ全エントリ 0) で **疎データ全体の分散** に対する 2 次元近似の比は本質的に小さくなるため。重要なのは「主要な変動方向を 2 軸が拾えているか」で、後段の β_{typeA} が $SE \approx 0.10 / p < 0.001$ で得られ SEED 間でも同符号・同桁に再現することが間接的な validation になっている (polarity が雑音なら係数は不安定になるはず)。現設計は分散 = $\text{Var}(x) + \text{Var}(y)$ で 2 次元 polarity 平面の散らばりを測るため軸選択にも robust。

- 「バースト閾値 3.0 と 5 件はどう決めた？」

→ notebook 設定セルで変更可能 ([scripts/run_simple.py:57-58](#))。本研究ではこの値の頑健性まではスコープ外。閾値を変えると TypeA/B 件数のスケールは動くが、median 分割なので相対的な分類は大きくは変わらない設計。

- 「quality の LLM ラベル 200 件で足りる？」

→ 事前学習 CV AUC = 0.894。本番 14k notes でも quality は最大の effect ($\beta = -1.86$) を維持し、寄与度 (domain_trust 44%) は事前知識と整合。再学習は `scripts/experiments/train_quality_model.py`。

- 「trend を control に入れたほうが良くない？」

→ 目的変数 deleted と **同じ生データ** (helpfulnessLevel 系列) から作られる **bad control**。入れると目的変数の一部を control する形になり β_{typeA} を不当に押し下げる。

- 「type_a と log_ratings_count の正相関で多重共線性は？」

→ バースト判定が min_count=5 件以上を要求するため構造的な正相関の懸念はあった ([src/simple/regression.py:14-20](#) 参照) が、本番実測では杞憂だった。本番実測値:

- type_a VIF = **7.43** (注意), type_b VIF = **7.49** (注意), quality VIF = **1.01** (OK), log_ratings_count VIF = **1.12** (OK)
- 相関 $\text{corr}(\text{type_a}, \text{log_ratings_count}) = \mathbf{0.032}$ (ほぼゼロ) — 当初懸念した正相関は実データでは消えており、log_ratings_count は独立な control として機能している。
- type_a / type_b の VIF が 5 を超えるのは別の構造的理由による: $\text{corr}(\text{type_a}, \text{type_b}) = -0.923$ (1 note 1 バーストかつ 96% のノートが A/B どちらかに分類されるため、ほぼ相補な指標になる)。catastrophic 判定の VIF>10 には届かず、実際 SE も ≈ 0.10 に収まり全係数 $p < 0.001$ で結論は安定。

サンプル設計と外的妥当性

- 「deleted は CURRENTLY_RATED_NOT_HELPFUL だけ? NEEDS_MORE_RATINGS はどうした?」
→ 回帰は CURRENTLY_RATED_HELPFUL / CURRENTLY_RATED_NOT_HELPFUL の 2 値のみで実施 ([src/simple/regression.py:28](#) の VALID_STATUSES)。「最終的な合意に至った note」だけが分析対象。
→ 副作用として、NEEDS_MORE_RATINGS の note は除外される。本番では検出バースト 106,673 件のうち最終特徴量に残るのは 13,695 件のみで、**バースト持ち note の大半は合意未達**。この選抜の影響は限界として要言及。
- 「frac=0.30 単一規模での検証で十分?」
→ 本番 $p < 0.001$ で SE も小さいため、frac=0.50, 1.0 に上げてても点推定はほとんど動かない見込み。SEED=1 の保険実行で同符号・同桁を確認することで頑健性は担保。
- 「政治トピック判定がキーワード40語ベース、これでカバー漏れない?」
→ 単語境界 \b 付き正規表現で vote → devote 等の誤マッチは排除済み ([src/simple/topic.py](#))。ただし recall 側 (政治的だがキーワードに無い note) は取りこぼす。今回の被験 14k notes は "政治の中でも辞書ヒットした部分" の subsample である点は限界。
- 「1 note 1 バーストの簡略化で情報を捨てていない?」
→ 捨てている (break で先頭バーストのみ採用、[src/simple/burst.py:55](#))。複数バーストを区別する設計 (e.g. 最も激しいバーストを採用、バースト回数を control 変数化) は今後の拡張候補。
- 「multiple comparison 補正は?」
→ 本研究はスコープ外。素直に $p < 0.05$ で判定。本番では全 4 変数とも $p < 0.001$ なので Bonferroni 補正 ($\alpha = 0.05/4 = 0.0125$) でも結論は同じ。